Robótica Probabilística
Metodologia e Revisão Bibliográfica

Isabel Monteiro de Castro Assunção – Matrícula: 2023060340
Theo Fonseca Cruz – Matrícula: 2023059440

Revisão Bibliográfica

O trabalho combina duas linhas que, na literatura consultada, aparecem separadas. De um lado, filtros recursivos que mantêm uma estimativa densa de profundidade, com incerteza, e a transportam entre quadros usando o movimento conhecido da câmera. De outro, controladores baseados em funções barreira de controle (CBF) que usam o campo de visão ocluído como conjunto seguro, mas o tratam como exatamente conhecido. A revisão concentra-se na parte probabilística, que é onde está a contribuição do trabalho, e trata o controle de forma breve.

Filtro de Bayes gaussiano e filtro de Kalman estendido

Thrun, Burgard e Fox [1] formulam a estimação de estado em robótica como um filtro de Bayes recursivo, em que a crença sobre um estado não observado diretamente é atualizada em duas etapas: a predição, que usa o modelo de movimento e o comando aplicado, e a correção, que incorpora a medição do sensor. Quando a crença é gaussiana, $\mathcal{N}(\boldsymbol{\mu}, \Sigma)$, e os modelos são lineares, o filtro de Kalman é a solução exata. Para modelos não lineares, o filtro de Kalman estendido (EKF) propaga a média pela função de movimento e lineariza essa função em torno da média para propagar a covariância, $\Sigma^{-} = F\Sigma F^{T} + Q$, em que F é o jacobiano do modelo e Q é o ruído de processo. Essa é a estrutura adotada neste trabalho: o estado oculto é o vetor de alcances da fronteira de visibilidade, o movimento conhecido do observador faz o papel do comando, e o LiDAR fornece as medições. A não linearidade está inteiramente na predição, pois mover o observador altera de forma não linear o alcance e o ângulo sob os quais cada ponto da fronteira é visto. A correção, por sua vez, é linear, porque cada feixe mede diretamente o seu próprio alcance.

Propagação de mapas de profundidade entre quadros

O problema de transportar uma fronteira estimada de um referencial para o seguinte tem um análogo direto em visão computacional: a estimação recursiva de mapas de profundidade por pixel a partir de sequências de imagens com movimento conhecido. Os dois trabalhos a seguir mantêm, para cada pixel, uma estimativa gaussiana de profundidade (ou de disparidade, ou de inversa da profundidade) e, a cada quadro, movem essa estimativa para o novo referencial, reamostram-na na grade de pixels e aumentam sua variância. O presente trabalho aplica a mesma ideia em uma dimensão, ao alcance da primeira oclusão em cada feixe.

Matthies, Kanade e Szeliski [2] introduzem um filtro de Kalman *icônico*, em que o estado é a disparidade de cada pixel e não a posição de um conjunto esparso de características. A etapa de predição (Seção 4.4 do artigo) usa o mapa de disparidade atual e o movimento conhecido para calcular para onde cada pixel se desloca no quadro seguinte e qual será a sua nova profundidade. Como os pontos deslocados não caem sobre a grade de pixels, a disparidade predita em cada pixel é obtida por interpolação bilinear dos pontos deslocados que o cercam. A variância é inflada por um fator multiplicativo e, em seguida, deslocada e interpolada da mesma forma que a média. No Apêndice C, os autores derivam, para o caso unidimensional, o jacobiano da interpolação linear em relação às disparidades e às posições dos pontos deslocados. Esse jacobiano contém um termo

proporcional à inclinação local do mapa, que acopla o erro de posição ao erro de profundidade. Os autores observam ainda que interpolar duas estimativas independentes reduz a variância pela metade no ponto médio, efeito que pode tornar o filtro excessivamente confiante. Esse artigo contribui para o presente trabalho com a estrutura da predição (deslocar, reamostrar, propagar a variância) e com a forma do jacobiano: as linhas da matriz F derivadas na metodologia são a versão polar desse resultado. Ele também deixa em aberto exatamente os pontos que este trabalho precisa resolver. Os autores mantêm apenas a variância de cada pixel e afirmam que transformar a covariância completa na predição complicaria significativamente o algoritmo. Eles detectam descontinuidades de profundidade para a suavização, mas declaram não ter explorado a propagação dessas descontinuidades entre quadros. Por fim, notam que detectar desoclusões não é possível sob a hipótese de um campo de disparidade contínuo, mas passa a ser possível quando as descontinuidades são conhecidas.

Engel, Sturm e Cremers [3] retomam essa ideia em odometria visual monocular semidensa. Cada pixel com gradiente de imagem relevante carrega uma gaussiana sobre a inversa da profundidade. Na propagação (Seção 2.2 do artigo), o ponto 3D correspondente a cada pixel é projetado no novo quadro e atribuído ao pixel mais próximo, e a variância é propagada como na predição de um EKF, com um termo aditivo de incerteza de predição. Três escolhas desse trabalho são incorporadas aqui. A primeira é a regra de colisão: quando duas hipóteses chegam ao mesmo pixel, elas são fundidas se forem estatisticamente compatíveis (dentro de 2σ); caso contrário, a mais distante é considerada ocluída e descartada. Essa regra é a mesma que garante que a fronteira predita continue representando a primeira oclusão. A segunda é o teste estatístico para preservar arestas: na regularização, vizinhos que diferem por mais de 2σ não contribuem um para o outro. A terceira é o cuidado com a correlação entre vizinhos: as variâncias não são reduzidas na regularização justamente porque hipóteses vizinhas são fortemente correlacionadas. Por outro lado, o método usa propagação direta (cada pixel antigo é enviado a um pixel novo), o que deixa buracos no novo mapa. Esses buracos e os pixels desocluídos não recebem nenhuma informação a priori: são preenchidos a partir dos vizinhos ou inicializados diretamente pela próxima observação.

Os dois trabalhos, portanto, fornecem o mecanismo de transporte e reamostragem da estimativa, mas deixam dois pontos abertos que se tornam centrais quando a estimativa define um conjunto de segurança. O primeiro são as desoclusões: regiões reveladas pelo movimento não recebem distribuição a priori. O segundo são as descontinuidades nas bordas de objetos, cuja propagação entre quadros não é tratada por Matthies et al. e é resolvida apenas por descarte em Engel et al. Além disso, nenhum dos dois mantém a covariância completa entre elementos. O problema unidimensional deste trabalho, com algumas centenas de feixes, permite tratar os três pontos explicitamente.

Controle com funções barreira e visibilidade sob oclusão

Ames et al. [4] apresentam a teoria de funções barreira de controle. Para um sistema afim no controle, $\dot{x} = f(x) + g(x)u$, e um conjunto seguro definido como o superconjunto de nível zero de uma função h, $\mathcal{C} = \{x : h(x) \geq 0\}$, h é uma CBF se existe uma função α de classe $\mathcal{K}_\infty$ estendida tal que $\sup_u [L_f h(x) + L_g h(x) u] \geq -\alpha(h(x))$. Qualquer controlador Lipschitz que satisfaça essa condição torna $\mathcal{C}$ invariante para frente e, além disso, assintoticamente estável, de modo que perturbações que levem o sistema para fora do conjunto são corrigidas. Como a condição é afim em u, a forma mínima de modificar um controlador nominal para garantir segurança é um programa quadrático (CBF-QP) com uma restrição linear. Essa formulação define a estrutura do controlador deste trabalho. Ela também evidencia o motivo de se usar uma fronteira conservadora: a garantia vale para o conjunto definido por h, e se h é calculada a partir de uma estimativa, a garantia passa a valer para o conjunto estimado e não para o real.

Zhou et al. [5] aplicam CBFs a um problema de perseguição sob oclusão, em que um robô deve manter um alvo móvel dentro do seu campo de visão ocluído. A função barreira de visibilidade é o

oposto da distância com sinal do alvo ao campo de visão ocluído, $h(t, x) = -d(y(t), \mathcal{F}(x))$, que é positiva quando o alvo está visível. Os autores mostram que essa função é Lipschitz, embora não seja diferenciável em todos os pontos, e por isso usam gradientes generalizados e uma formulação variante no tempo. O controlador resolve um QP com as restrições de visibilidade e de segurança, e uma variável de folga garante sua factibilidade. Como não há expressão analítica para o gradiente do campo de visão, ele é aproximado por diferenças finitas resolvidas por mínimos quadrados. Nos experimentos, o campo de visão é obtido por traçado de raios em um mapa de ocupação construído por SLAM, e é tratado como exatamente conhecido. Esse artigo fornece a função barreira usada aqui e o modo de lidar com sua falta de suavidade. O presente trabalho altera justamente a hipótese de conhecimento exato: em vez de um campo de visão obtido de um mapa, usa-se um conjunto visível estimado, sem mapa, com incerteza explícita, e a função barreira passa a ser avaliada sobre uma fronteira de confiança.

Síntese

Os trabalhos de Matthies et al. e Engel et al. mostram como manter e transportar uma estimativa densa de profundidade com incerteza, mas não a usam para controle e deixam abertas desoclusões e descontinuidades. Os trabalhos de Ames et al. e Zhou et al. mostram como transformar visibilidade em uma restrição de controle, mas supõem que o conjunto visível é conhecido. O trabalho proposto liga as duas linhas: estima a fronteira de visibilidade com um filtro gaussiano que trata explicitamente mudanças de visibilidade, descontinuidades e a covariância da reamostragem, e alimenta o controlador com uma fronteira de confiança derivada dessa estimativa.

Metodologia

Cenário

O cenário é uma simulação bidimensional com obstáculos poligonais estáticos. Um observador móvel deve manter um alvo dentro do seu campo de visão. A pose do observador é conhecida, assim como o comando de movimento aplicado a cada passo, de modo que a translação $\Delta\mathbf{p}$ e a rotação $\Delta\psi$ entre dois instantes consecutivos são conhecidas e expressas no referencial do observador no instante anterior. Nenhum mapa do ambiente é mantido: toda a informação sobre os obstáculos está na estimativa da fronteira, que é expressa no referencial do observador. A posição do alvo, $\mathbf{y}(t)$, e sua velocidade são supostas conhecidas, como em [5], para que a comparação isole o efeito da estimativa da fronteira.

O campo de visão sem oclusão é um setor circular com abertura β e alcance $r_{\max}$, discretizado em N feixes com ângulos $\theta_1, \ldots, \theta_N$ igualmente espaçados de $\Delta\theta$ no referencial do observador. Para cada feixe, $B(\theta_i)$ é a distância até o primeiro obstáculo, saturada em $r_{\max}$. O estado do filtro é

$$\mathbf{b}_k = \begin{bmatrix} B(\theta_1) & \cdots & B(\theta_N) \end{bmatrix}^T, \qquad \mathbf{b}_k \sim \mathcal{N}(\boldsymbol{\mu}_k, \Sigma_k), \tag{1}$$

com covariância Σ_k completa, e não diagonal, pelos motivos discutidos na propagação da covariância. O conjunto visível é a região limitada pela fronteira, $\{r\,\mathbf{u}(\theta) : 0 \le r \le B(\theta)\}$, com $\mathbf{u}(\theta) = [\cos\theta,\ \sin\theta]^T$.

O LiDAR fornece um alcance por feixe,

$$z_i = B(\theta_i) + v_i, \qquad v_i \sim \mathcal{N}(0, \sigma_r^2), \tag{2}$$

de modo que cada feixe mede diretamente o seu próprio elemento do estado. Um feixe sem retorno indica apenas que $B(\theta_i) \ge r_{\max}$; como a fronteira é saturada no alcance do sensor, ele é incorporado como uma pseudomedição $z_i = r_{\max}$. No simulador, as medições são geradas por traçado de raios sobre os polígonos, com ruído gaussiano, e o mesmo traçado de raios sem ruído fornece a fronteira real, usada apenas como referência (oráculo) na avaliação.

Modelo de predição

A predição responde, para cada feixe, à seguinte pergunta: dada a última estimativa da fronteira e o movimento conhecido, que alcance e que variância esse feixe deve esperar? A resposta é construída em quatro etapas: transformar os pontos da fronteira antiga para o novo referencial, reamostrá-los nos ângulos dos feixes, propagar a covariância e tratar as mudanças de visibilidade.

O transporte da fronteira entre referenciais, isoladamente, não garante que ela continue representando a primeira oclusão. Como os obstáculos são estáticos, cada ponto transportado continua sendo um ponto sobre um obstáculo, mas o movimento altera a visibilidade de três formas: um ponto antes visível pode ficar atrás de outro obstáculo (oclusão nova); uma região antes escondida atrás de uma aresta pode ser revelada (desoclusão); e uma rotação pode trazer para o setor direções que não estavam no campo de visão anterior (região recém-explorada). Além disso, interpolar entre pontos de objetos diferentes cria superfícies inexistentes. As quatro etapas abaixo tratam esses casos de forma explícita, e o que não puder ser previsto pela geometria é detectado na correção.

Transformação. O ponto final antigo do feixe j é $\mu_j \mathbf{u}(\theta_j)$. No novo referencial, ele passa a

$$\mathbf{p}'_j = \mathbf{R}(-\Delta\psi)\,(\mu_j \mathbf{u}(\theta_j) - \Delta\mathbf{p}), \qquad \rho_j = \|\mathbf{p}'_j\|, \qquad \phi_j = \operatorname{atan2}(p'_{j,y},\, p'_{j,x}), \tag{3}$$

em que $\mathbf{R}(\cdot)$ é a matriz de rotação no plano. Sob rotação pura, $\rho_j = \mu_j$ e todos os ângulos se deslocam igualmente de $-\Delta\psi$. Sob translação, pontos próximos se deslocam mais em ângulo do que pontos distantes (paralaxe), de modo que os ϕ_j deixam de ser igualmente espaçados e podem até mudar de ordem.

Reamostragem angular. Os pontos transportados não caem sobre os ângulos dos feixes, e a predição precisa ser reamostrada. A reamostragem é feita sobre pares de feixes que eram vizinhos na varredura anterior, $(a, b) = (j, j+1)$, porque dois pontos vizinhos na varredura antiga são os únicos que podem pertencer a um mesmo trecho contínuo de superfície. Para um novo feixe θ_i cercado por um par, $\phi_a \le \theta_i \le \phi_b$, o alcance predito é

$$\mu_i^- = w_i\,\rho_a + (1 - w_i)\,\rho_b, \qquad w_i = \frac{\phi_b - \theta_i}{\phi_b - \phi_a}. \tag{4}$$

Para passos pequenos, a e b são simplesmente os feixes antigos i e $i \pm 1$, e a predição se reduz a uma combinação dos vizinhos. Quando a paralaxe faz com que mais de um par cerque o mesmo θ_i, isto é, quando uma superfície próxima passa na frente de uma distante, toma-se o par de menor alcance predito. Essa é a versão polar da regra de colisão de Engel et al. [3] e é o que mantém a predição associada à primeira oclusão.

Propagação da covariância. A predição é linearizada como em um EKF [1]:

$$\Sigma_k^- = F\,\Sigma_{k-1}\,F^T + Q, \qquad F_{ij} = \frac{\partial \mu_i^-}{\partial \mu_j}. \tag{5}$$

Uma variação em μ_j move o ponto final ao longo do seu feixe antigo, o que altera tanto o novo alcance quanto o novo ângulo:

$$\frac{\partial \rho_j}{\partial \mu_j} = \cos(\phi_j - \theta_j + \Delta\psi), \qquad \frac{\partial \phi_j}{\partial \mu_j} = \frac{\sin(\theta_j - \Delta\psi - \phi_j)}{\rho_j}. \tag{6}$$

Pela regra da cadeia através da interpolação, cada linha de F tem duas entradas não nulas:

$$F_{ia} = w_i \frac{\partial \rho_a}{\partial \mu_a} + \frac{(\rho_a - \rho_b)\,w_i}{\phi_b - \phi_a}\,\frac{\partial \phi_a}{\partial \mu_a}, \tag{7}$$

$$F_{ib} = (1 - w_i)\frac{\partial \rho_b}{\partial \mu_b} + \frac{(\rho_a - \rho_b)(1 - w_i)}{\phi_b - \phi_a}\,\frac{\partial \phi_b}{\partial \mu_b}. \tag{8}$$

O primeiro termo transporta o erro de alcance. O segundo transporta o deslocamento angular, multiplicado pela inclinação local da fronteira, $(\rho_a - \rho_b)/(\phi_b - \phi_a)$, e por isso só é relevante em superfícies oblíquas. Ele corresponde ao termo de inclinação do jacobiano de interpolação de Matthies et al. [2]. Sob rotação pura, F se reduz aos pesos de interpolação w_i e $1 - w_i$.

Como a cena é estática, Q não representa movimento dos obstáculos, mas apenas o erro de interpolação e de modelo. Ele cresce com o movimento e perto de arestas:

$$Q_{ii} = q_0 + q_v \, \|\Delta \mathbf{p}\|^2 + q_\omega \, \Delta\psi^2 + q_e \, \mathbf{1}\big[\, i \text{ é vizinho de uma aresta} \,\big]. \tag{9}$$

Duas consequências justificam manter Σ completa. Primeiro, a interpolação correlaciona feixes vizinhos, já que dois feixes novos podem depender do mesmo ponto antigo. Segundo, a interpolação reduz a variância: dois erros independentes de 10 cm interpolados com pesos iguais resultam em cerca de 7 cm. Matthies et al. apontam esse efeito e sugerem contorná-lo com uma mistura de variâncias, e Engel et al. o evitam deixando de reduzir variâncias na regularização. Aqui ele é tratado de forma exata: com Σ completa, a correlação gerada por uma interpolação é registrada, e uma nova interpolação de valores já correlacionados não produz uma redução espúria. É a covariância completa, somada a Q, que impede o filtro de se tornar excessivamente confiante em feixes que ficam vários passos sem medição.

Mudanças de visibilidade e descontinuidades. A interpolação simples é incorreta em três situações, cada uma tratada separadamente: descontinuidades (arestas), desoclusões e regiões recém-exploradas.

Arestas e oclusões novas. Quando os dois pontos de um par pertencem a objetos diferentes, por exemplo uma caixa a 3 m e uma parede a 8 m, interpolar criaria uma parede fictícia a cerca de 5,5 m em espaço livre. Dois pontos vizinhos transportados são considerados parte da mesma superfície apenas se seus alcances forem próximos em relação à sua incerteza:

$$|\rho_a - \rho_b| \le \max\!\Big(\tau,\; 3\sqrt{\sigma_a^2 + \sigma_b^2}\Big), \qquad \sigma_j^2 = \Big(\frac{\partial \rho_j}{\partial \mu_j}\Big)^2 \Sigma_{jj}. \tag{10}$$

O termo de incerteza impede que o ruído do sensor, sozinho, divida uma parede plana em arestas falsas, e τ é um limiar mínimo em metros. O critério é análogo ao teste de 2σ usado por Engel et al. para preservar arestas. Se o teste falha, o par é marcado como aresta e não se interpola através do salto. Para um feixe cujo raio ainda atinge a superfície próxima, a predição é o ponto mais próximo, $\mu_i^- = \min(\rho_a, \rho_b)$, isto é, a primeira oclusão, e a linha de F tem uma única entrada, $\partial\rho/\partial\mu$ do ponto escolhido. O termo q_e em Q representa a possibilidade de o canto cair de qualquer um dos lados do feixe. A mesma regra do ponto mais próximo vale quando dois pontos transportados caem sobre um mesmo feixe, o que caracteriza uma oclusão nova. Desse modo, a aresta detectada em um passo é propagada para o seguinte junto com os pontos que a definem, que é o ponto deixado em aberto por Matthies et al.

Desoclusões. Um feixe dentro de um par marcado como aresta pode passar além do canto e olhar para uma região que estava escondida no passo anterior. Seja $\mathbf{c}$ o ponto transportado do feixe de canto (o último feixe antigo que atingia a superfície próxima) e $\mathbf{d} = \mathbf{R}(-\Delta\psi)\,\mathbf{u}(\theta_c) = \mathbf{u}(\theta_c - \Delta\psi)$ a sua direção transportada. O novo feixe $s\,\mathbf{u}(\theta_i)$ cruza o prolongamento desse raio, $\mathbf{c} + t\,\mathbf{d}$, em

$$s_i = \frac{\mathbf{c} \times \mathbf{d}}{\mathbf{u}(\theta_i) \times \mathbf{d}}, \qquad t = \frac{\mathbf{c} \times \mathbf{u}(\theta_i)}{\mathbf{u}(\theta_i) \times \mathbf{d}}, \tag{11}$$

em que $\times$ é o produto vetorial bidimensional. Esse cálculo também separa os dois casos: se $t < 0$, o feixe cruza o raio antes do canto, ainda atinge a superfície próxima e vale a regra do ponto mais próximo; se $t \ge 0$, o feixe entra na antiga sombra e é tratado como desoclusão. Nesse caso, o espaço antes de s_i foi visto livre no passo anterior, de modo que s_i é um limite inferior para o

alcance. Ele é limitado superiormente pelo alcance do fundo, r_{far}, dado pelo ponto distante do par (e saturado em $r_{\max}$). A distribuição a priori é

$$\mu_i^- = \frac{s_i + r_{\text{far}}}{2}, \qquad \sigma_i^- = \max\Big(\frac{\mu_i^- - s_i}{\kappa_\varepsilon},\, \sigma_{\min}\Big), \qquad \kappa_\varepsilon = \Phi^{-1}(1-\varepsilon), \tag{12}$$

o que coloca a fronteira de confiança exatamente sobre o limite geométrico, $\mu_i^- - \kappa_\varepsilon \sigma_i^- = s_i$. O piso $\sigma_{\min}$ evita excesso de confiança quando $s_i \approx r_{\text{far}}$. Por exemplo, com $s_i = 3\,\text{m}$, $r_{\text{far}} = 8\,\text{m}$ e $\varepsilon = 5\%$, obtém-se $\mu_i^- = 5{,}5\,\text{m}$ e $\sigma_i^- \approx 1{,}5\,\text{m}$. O produto $\mathbf{c} \times \mathbf{d}$ não depende de μ_c, porque uma variação de μ_c move $\mathbf{c}$ ao longo de $\mathbf{d}$. Portanto, a linha correspondente de F é nula, e o elemento desocluído não tem covariância cruzada com a estimativa anterior. Esse tratamento substitui a ausência de informação a priori em pixels desocluídos, presente em Matthies et al. e Engel et al., por uma distribuição limitada pela geometria do passo anterior.

Regiões recém-exploradas. Quando o observador gira, feixes entram no setor pelas laterais sem nenhum ponto antigo de nenhum dos lados. A linha de F também é nula, a média a priori é o alcance do feixe coberto mais próximo (ou $r_{\max}$) e a variância é grande, σ_0^2. O ganho de Kalman fica então próximo de um, e a primeira leitura define o elemento.

Validade. Longe de arestas, o modelo supõe que um ponto da superfície se desloca no máximo cerca de um feixe por passo,

$$\frac{\|\Delta\mathbf{p}\|}{\rho} + |\Delta\psi| \lesssim \Delta\theta, \tag{13}$$

o que limita o passo de tempo para uma dada velocidade e um dado número de feixes.

Correção

A correção é uma atualização de Kalman linear padrão [1]. A matriz H seleciona os feixes medidos no passo, e a covariância do ruído de medição é $\sigma_r^2 I$. Antes da atualização, cada leitura é comparada com a sua predição por um teste χ^2 sobre a inovação,

$$\frac{(z_i - \mu_i^-)^2}{\Sigma_{ii}^- + \sigma_r^2} > \chi^2_{1,\,1-\gamma}. \tag{14}$$

Uma leitura que falha no teste indica uma mudança de visibilidade que a geometria não previu, por exemplo um obstáculo antes totalmente escondido que passa a ser a primeira oclusão. Nesse caso, o elemento é reinicializado a partir da medição: a média recebe z_i, a variância recebe σ_r^2 e as covariâncias cruzadas da linha e da coluna i são zeradas, o que preserva a semidefinição positiva de Σ. As demais leituras são incorporadas pela atualização usual, na forma de Joseph para estabilidade numérica.

Um objetivo do projeto é que o filtro funcione quando apenas parte dos feixes é medida a cada passo. A ideia é que muitas medições esparsas ao longo do tempo possam definir bem a fronteira, enquanto a predição leva informação para os feixes ainda não medidos. A covariância completa contribui para isso, pois a medição de um feixe também corrige os vizinhos correlacionados com ele. Os detalhes dessa configuração ainda estão sendo definidos.

Modelo de controle

O observador tem estado $\mathbf{q} = (\mathbf{p}, \psi)$ e é modelado como um sistema omnidirecional sem deriva, afim no controle,

$$\dot{\mathbf{p}} = \mathbf{R}(\psi)\,\mathbf{v}, \qquad \dot{\psi} = \omega, \qquad \mathbf{u} = [\,\mathbf{v}^T \;\; \omega\,]^T, \tag{15}$$

em que $\mathbf{v}$ é a velocidade no referencial do observador. O modelo uniciclo usado em [5] é o caso particular com velocidade lateral nula. Em um passo Δt, o comando produz $\Delta\mathbf{p} \approx \mathbf{v}\,\Delta t$ e $\Delta\psi = \omega\,\Delta t$, que são exatamente as grandezas usadas no modelo de predição.

A partir da estimativa, define-se para cada feixe uma fronteira de confiança

$$B_\varepsilon(\theta_i) = \mu_i - \kappa_\varepsilon\,\sigma_i, \qquad \kappa_\varepsilon = \Phi^{-1}(1-\varepsilon), \tag{16}$$

que fica aquém da fronteira real com probabilidade de pelo menos $1-\varepsilon$ em cada feixe. Unindo os pontos $B_\varepsilon(\theta_i)\,\mathbf{u}(\theta_i)$ obtém-se um polígono estrelado, o conjunto visível de confiança V_ε. A garantia é marginal, por feixe; uma garantia conjunta sobre todos os feixes exigiria um quantil mais conservador, como ε/N pela desigualdade de Bonferroni.

Seguindo Zhou et al. [5], a função barreira é o oposto da distância com sinal do alvo, expresso no referencial do observador, ao conjunto visível de confiança,

$$h_k = -d(\bar{\mathbf{y}}_k,\, V_\varepsilon), \qquad \bar{\mathbf{y}}_k = \mathbf{R}(-\psi_k)\,(\mathbf{y}(t_k) - \mathbf{p}_k), \tag{17}$$

com d negativa no interior, de modo que $h_k \geq 0$ se e somente se o alvo está dentro de V_ε. Como não há mapa, a dependência de V_ε em relação ao movimento do observador não pode ser obtida por traçado de raios, como em [5]. Ela é obtida pelo próprio modelo de predição: para um conjunto de pequenos deslocamentos $\{\delta\mathbf{q}_m\}$, aplica-se a predição a $(\boldsymbol{\mu}_k, \Sigma_k)$, recalcula-se V_ε e avalia-se h. O gradiente $\mathbf{g}_k = \nabla_{\delta\mathbf{q}}\, h_k$ é então estimado por mínimos quadrados, como em [5], o que também fornece um elemento do gradiente generalizado nos pontos em que h não é diferenciável. O movimento do alvo entra pelo termo $\partial h/\partial t = -\nabla_{\bar{\mathbf{y}}} d^T\,\mathbf{R}(-\psi_k)\,\dot{\mathbf{y}}$.

O controlador resolve o CBF-QP [4]

$$\mathbf{u}^* = \arg\min_{\mathbf{u}\in\mathcal{U},\,\delta\geq 0} \|\mathbf{u} - \mathbf{u}_{\text{nom}}\|^2 + \lambda\,\delta^2 \quad \text{s.a.} \quad \mathbf{g}_k^T\,\mathbf{u} + \frac{\partial h}{\partial t} + \alpha(h_k) \geq -\delta, \tag{18}$$

em que $\mathbf{u}_{\text{nom}}$ é um controlador nominal simples (por exemplo, seguir uma trajetória de referência), $\mathcal{U}$ impõe limites de velocidade, α é linear, $\alpha(h) = \gamma h$, e a folga δ, penalizada por λ grande, garante a factibilidade quando os limites de $\mathcal{U}$ impedem satisfazer a restrição, como em [5]. A restrição de segurança contra colisão de [5] pode ser acrescentada usando as próprias leituras do LiDAR, mas não é o foco do trabalho.

Protocolo de comparação

O mesmo controlador é alimentado com três fronteiras: a fronteira real (oráculo), a média estimada $\boldsymbol{\mu}$ (equivalente a $\kappa_\varepsilon = 0$) e a fronteira de confiança B_ε. Como apenas a fronteira muda entre os casos, a comparação isola o efeito da estimativa. Do lado do controle, mede-se a fração do tempo em que o alvo permanece visível em relação à fronteira real, o número e a duração das violações reais de visibilidade e o conservadorismo, dado pela diferença média entre B_ε e a fronteira real. Do lado da estimação, mede-se o erro quadrático médio por feixe e o erro quadrático normalizado pela covariância (NEES), separados por tipo de feixe (interior, vizinho de aresta, desocluído e recém-explorado). O NEES verifica se a covariância propagada na reamostragem angular é consistente com o erro real, isto é, se o filtro não está otimista nem pessimista em cada um dos casos especiais.

Referências

[1] S. Thrun, W. Burgard e D. Fox, *Probabilistic Robotics*. Cambridge, MA: MIT Press, 2005.

[2] L. Matthies, T. Kanade e R. Szeliski, "Kalman Filter-Based Algorithms for Estimating Depth from Image Sequences," *International Journal of Computer Vision*, v. 3, n. 3, pp. 209–238, 1989. DOI: 10.1007/BF00133032

[3] J. Engel, J. Sturm e D. Cremers, "Semi-Dense Visual Odometry for a Monocular Camera," em *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, Sydney, Australia, 2013, pp. 1449–1456. DOI: 10.1109/ICCV.2013.183

[4] A. D. Ames, S. Coogan, M. Egerstedt, G. Notomista, K. Sreenath e P. Tabuada, "Control Barrier Functions: Theory and Applications," em *Proceedings of the European Control Conference (ECC)*, Naples, Italy, 2019, pp. 3420–3431. DOI: 10.23919/ECC.2019.8796030

[5] M. Zhou et al., "Control Strategies for Pursuit-Evasion Under Occlusion Using Visibility and Safety Barrier Functions," em *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, Atlanta, GA, USA, 2025. arXiv: 2411.01321.